
Aprimoramento do TabPFN para Classificação Tabular: Redução de Dimensionalidade via PCA e Avaliação Robusta por Validação Cruzada

Davi de Souza
Curso de Ciência da Computação
Universidade Federal de Viçosa – Campus Florestal
davi.souza@ufv.br

1 Introdução

No TPF-01, foi reproduzido um experimento do artigo *TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second* (1), que propõe um Transformer pré-treinado (*Prior-Data Fitted Network*) capaz de realizar classificação tabular por *in-context learning*, sem a necessidade de treinamento específico para cada novo conjunto de dados. A reprodução utilizou o *Breast Cancer Wisconsin Dataset* (569 amostras, 30 atributos numéricos, classificação binária) e obteve 98,25% de acurácia e AUC de 1,00 em um único *split* de teste (80%/20%, `random_state=42`), resultados consistentes com o desempenho reportado pelos autores em conjuntos de dados pequenos.

O objetivo desta segunda fase (TPF-02) é propor e avaliar modificações no ambiente experimental que (i) reduzam a complexidade computacional do modelo e (ii) aumentem a confiabilidade da estimativa de generalização. Como o TabPFN é um modelo de fundação pré-treinado – e não um modelo treinado do zero pelo usuário –, as modificações aqui propostas atuam sobre o *pipeline* de dados e sobre o protocolo de avaliação, mantendo a mesma arquitetura Transformer subjacente, conforme permitido pela especificação do trabalho.

2 Modificações e Justificativas

Foram propostas duas modificações complementares em relação ao TPF-01:

(1) Redução de dimensionalidade via PCA. Os 30 atributos originais do *dataset* foram padronizados (média zero, variância unitária) e projetados via Análise de Componentes Principais (PCA), retraindo o menor número de componentes que explica pelo menos 95% da variância total dos dados. Esse procedimento reduziu a dimensionalidade de 30 para 10 atributos (redução de 66,7%). A justificativa é dupla: como o mecanismo de atenção do TabPFN opera sobre o conjunto de atributos como parte do contexto de entrada, menos atributos implicam menor custo computacional por *forward pass*; além disso, muitos dos 30 atributos do *Breast Cancer Wisconsin Dataset* são estatisticamente correlacionados (por exemplo, medidas de raio, perímetro e área do mesmo núcleo celular), de modo que a informação relevante pode ser preservada em um subespaço de menor dimensão, potencialmente reduzindo ruído e risco de *overfitting* a atributos redundantes.

(2) Avaliação por validação cruzada estratificada (10-fold). O TPF-01 avaliou o modelo em um único *split* de treino/teste. Embora reprodutível, essa metodologia está sujeita à variância da partição escolhida: um único *split* "sortudo" (ou "azarado") pode superestimar ou subestimar a capacidade real de generalização do modelo. Substituímos essa avaliação por uma validação cruzada estratificada com 10 *folds*, na qual o PCA é ajustado exclusivamente nos dados de treino de cada *fold* (evitando vazamento de informação do teste), e as métricas são reportadas como média $\pm$ desvio padrão sobre




Figure 1: Variância explicada acumulada pelos componentes principais do PCA. A linha tracejada vermelha marca o limiar de 95%, atingido com 10 componentes (linha pontilhada cinza).

Table 1: Comparação entre o baseline (TPF-01) e as configurações do TPF-02.

Configuração	Acurácia	AUC	F1-score	Tempo/execução (s)
TPF-01 (<i>split</i> único, 30 attrrs)	0,9825	0,9967	0,9861	2,03
TPF-02 (10-fold CV, 30 attrrs)	0,9807 $\pm$ 0,0123	0,9971 $\pm$ 0,0054	0,9847 $\pm$ 0,0098	2,30
TPF-02 (10-fold CV, PCA 10 attrrs)	0,9701 $\pm$ 0,0208	0,9956 $\pm$ 0,0055	0,9762 $\pm$ 0,0171	2,12

os 10 *folds*. Essa mudança não altera a arquitetura do modelo, mas fortalece a validade estatística da comparação entre configurações, indo além de um ajuste superficial de hiperparâmetros: trata-se de uma mudança no protocolo experimental que expõe a variabilidade real do desempenho do modelo.

Ambas as modificações foram aplicadas de forma isolada e conjunta, permitindo comparar: (a) o *baseline* do TPF-01 (*split* único, 30 atributos); (b) o mesmo conjunto de 30 atributos sob validação cruzada de 10 *folds*; e (c) os atributos reduzidos via PCA, também sob validação cruzada de 10 *folds*. A Figura 1 mostra a variância explicada acumulada em função do número de componentes principais, justificando a escolha de 10 componentes como o menor valor que atinge o limiar de 95%.

3 Configuração Experimental e Resultados

O ambiente experimental seguiu o TPF-01: Google Colab, Python 3, bibliotecas Scikit-Learn, Pandas e TabPFN, com GPU habilitada. O mesmo *dataset* (*Breast Cancer Wisconsin*, 569 amostras, 30 atributos) foi utilizado em todas as configurações, com `random_state=42` para reprodutibilidade. Para a validação cruzada, foi utilizado `StratifiedKFold` com $k = 10$, preservando a proporção de classes em cada *fold*. As métricas reportadas são acurácia, AUC (área sob a curva ROC) e F1-score, além do tempo médio de `fit+predict` por execução, como *proxy* de complexidade computacional.

A Tabela 1 resume os resultados obtidos nas três configurações avaliadas.

A Figura 2 apresenta a acurácia (10-fold CV) e o custo computacional médio por execução, comparando as configurações com e sem PCA. A Figura 3 mostra a curva de estabilidade da acurácia ao longo dos 10 *folds*, evidenciando a variabilidade do desempenho conforme a partição dos dados – funcionando como a curva de aprendizado/generalização solicitada na especificação.

Observamos que a validação cruzada de 10 *folds* sobre os 30 atributos originais produziu uma acurácia média (0,9807) muito próxima da obtida no *split* único do TPF-01 (0,9825), com um desvio padrão de apenas 0,0123. Isso indica que o resultado do TPF-01 *não* foi um artefato de um *split* favorável, reforçando a confiabilidade do *baseline* original. Já a redução de dimensionalidade via PCA levou a uma queda de aproximadamente 1 ponto percentual na acurácia média (0,9807 $\rightarrow$ 0,9701) e no F1-score (0,9847 $\rightarrow$ 0,9762), com AUC praticamente inalterada (0,9971 $\rightarrow$ 0,9956) e desvio padrão maior entre *folds* (0,0123 $\rightarrow$ 0,0208), indicando maior sensibilidade à partição dos dados quando




Figure 2: Esquerda: acurácia média (10-fold CV) com e sem PCA; a linha tracejada verde indica o resultado do *split* único do TPF-01. Direita: tempo médio de *fit*+*predict* por *fold*.




Figure 3: Estabilidade da acurácia entre os 10 *folds* da validação cruzada, para as configurações com e sem PCA. A linha tracejada verde indica o resultado do *split* único do TPF-01.

menos atributos estão disponíveis. Em termos de custo computacional, o ganho com PCA foi modesto (2,30s $\rightarrow$ 2,12s por execução, cerca de 8% de redução), inferior ao esperado dada a redução de 66,7% no número de atributos.

4 Discussão e Conclusões

Os resultados evidenciam um *trade-off* claro entre redução de complexidade e desempenho preditivo. A redução de dimensionalidade via PCA cumpriu seu objetivo de simplificar a entrada do modelo (30 $\rightarrow$ 10 atributos), mas o ganho de tempo computacional foi pequeno frente à perda de acurácia e F1-score, sugerindo que, para este conjunto de dados e para a arquitetura do TabPFN, o custo do *forward pass* não é dominado apenas pelo número de atributos – provavelmente o custo de atenção sobre as 569 amostras (dimensão do contexto) tem peso maior do que o número de colunas. Esse é um aprendizado relevante: nem toda redução de complexidade de entrada se traduz em ganho computacional proporcional em modelos baseados em atenção que operam sobre o eixo de amostras.

Por outro lado, a modificação metodológica de validação cruzada estratificada mostrou-se a contribuição mais valiosa deste trabalho: ela não alterou a arquitetura nem o desempenho médio de forma significativa, mas revelou a variabilidade real do modelo entre diferentes partições dos dados

(desvio padrão de 1,23 pontos percentuais na acurácia), informação que o *split* único do TPF-01 não conseguia capturar. Isso é particularmente importante para um conjunto de dados pequeno (569 amostras), onde a escolha do *split* pode ter impacto desproporcional na métrica reportada.

Como direções futuras, seria interessante investigar (i) o *fine-tuning* por gradiente do TabPFN v2, que já conta com suporte experimental na biblioteca oficial, permitindo adaptação mais direta aos dados; (ii) técnicas de seleção de atributos supervisionadas (em vez de PCA não supervisionado), que poderiam preservar mais informação discriminativa com o mesmo nível de redução dimensional; e (iii) a análise do comportamento do TabPFN à medida que o número de amostras (não apenas de atributos) varia, já que essa parece ser a dimensão que mais influencia o custo computacional observado.

Em suma, o TabPFN mostrou-se robusto às modificações propostas – mantendo desempenho próximo ao estado da arte mesmo com menos atributos e sob avaliação mais rigorosa –, mas o experimento também deixou claro que reduzir a complexidade de entrada de um modelo baseado em Transformer não garante, por si só, redução proporcional de custo computacional, sendo necessário compreender qual dimensão do dado (amostras ou atributos) domina o custo do mecanismo de atenção.

References

- [1] Hollmann, N., Müller, S., Eggenberger, K., Hutter, F. TabPFN: A Transformer That Solves Small Tabular Classification Problems in a Second. *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2207.01848.
- [2] Vaswani, A., et al. Attention Is All You Need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
- [3] Pedregosa, F., et al. Scikit-Learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12:2825–2830, 2011.